

December 1, 2025

1 1. Giới thiệu & Mục tiêu :

Mục tiêu của phần này là thực hiện giảm chiều vector nhúng từ (word embeddings) được huấn luyện sẵn từ mô hình GloVe, nhằm mục đích:

Biểu diễn trực quan các vector từ trong không gian 2D và 3D.

Tìm kiếm các từ có độ tương đồng cao nhất trong không gian đã giảm chiều.

So sánh sự khác biệt giữa kết quả tìm kiếm trong không gian 2D và 3D, qua đó đánh giá ảnh hưởng của việc giảm chiều đến cấu trúc ngữ nghĩa của vector.

2 2. Triển khai và kết quả thực nghiệm

```
[1]: from gensim.models import KeyedVectors
from sklearn.decomposition import PCA
from sklearn.metrics.pairwise import cosine_similarity
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D # giữ để tương thích các bản matplotlib
import numpy as np

# ===== CONFIG =====
MODEL_PATH = r"C:\Users\Z\Desktop\2025-code\NLP\week4\glove_model\src\data\wiki_giga_2024_50_MFT20_vectors_s
75_eta_0.075_combined.txt"
SUBSET_SIZE = 3000 # số từ đem đi giảm chiều (tăng/giảm tùy máy)
TOP_K = 10 # số láng giềng gần nhất sau khi giảm chiều
SEED = 123

# ===== LOAD MODEL =====
glove = KeyedVectors.load_word2vec_format(MODEL_PATH, no_header=True)
print(f"Loaded vectors: vocab={len(glove.index_to_key)}, dim={glove.
vector_size}")

# ===== INPUT WORD =====
word = input("Enter a word: ").strip().lower()
if word not in glove:
    print("Word not found in the vocabulary.")
```

```

raise SystemExit

# ===== CHỌN TẬP CON & ĐẢM BẢO CHỨA 'word' =====
# lấy SUBSET_SIZE từ phổ biến đầu tiên
words_subset = glove.index_to_key[:SUBSET_SIZE]
if word not in words_subset:
    # đảm bảo từ cần tra có mặt trong tập giảm chiều
    words_subset = [word] + [w for w in words_subset if w != word]
else:
    # đưa từ cần tra lên đầu cho tiện tham chiếu
    words_subset = [word] + [w for w in words_subset if w != word]

vectors_subset = np.array([glove[w] for w in words_subset])
center_idx = 0 # do đã đưa 'word' lên đầu

# ===== GIẢM CHIỀU 2D & 3D =====
pca_2d = PCA(n_components=2, random_state=SEED)
reduced_2d = pca_2d.fit_transform(vectors_subset)

pca_3d = PCA(n_components=3, random_state=SEED)
reduced_3d = pca_3d.fit_transform(vectors_subset)

print(f"PCA done. 2D shape: {reduced_2d.shape}, 3D shape: {reduced_3d.shape}")

# ===== TÌM TOP-K TRONG KHÔNG GIAN ĐÃ GIẢM =====
def topk_in_space(embeds, center_index, k):
    # embeds: (N, D_reduced)
    sims = cosine_similarity(embeds[center_index:center_index+1], embeds)[0]
    # loại chính nó và lấy top-k
    top_idx = np.argsort(sims)[::-1]
    top_idx = [i for i in top_idx if i != center_index][:k]
    return top_idx, sims[top_idx]

top_idx_2d, sims_2d = topk_in_space(reduced_2d, center_idx, TOP_K)
top_idx_3d, sims_3d = topk_in_space(reduced_3d, center_idx, TOP_K)

top_words_2d = [words_subset[i] for i in top_idx_2d]
top_words_3d = [words_subset[i] for i in top_idx_3d]

print(f"\nTop {TOP_K} nearest in REDUCED 2D space for '{word}':")
for w, s in zip(top_words_2d, sims_2d):
    print(f"{w:<15} {s:.4f}")

print(f"\nTop {TOP_K} nearest in REDUCED 3D space for '{word}':")
for w, s in zip(top_words_3d, sims_3d):
    print(f"{w:<15} {s:.4f}")

```

```

# ===== VẼ 2D: chỉ trung tâm + K láng giềng =====
plt.figure(figsize=(7, 6))

# vẽ từ trung tâm
plt.scatter(reduced_2d[center_idx, 0], reduced_2d[center_idx, 1],
            s=150, color="red", label=f"center: {word}")
plt.text(reduced_2d[center_idx, 0]+0.02, reduced_2d[center_idx, 1]+0.02,
         word, fontsize=11, color="red")

# vẽ K từ tương đồng nhất
for i in top_idx_2d:
    x, y = reduced_2d[i]
    plt.scatter(x, y, s=80, color="steelblue")
    plt.text(x+0.02, y+0.02, words_subset[i], fontsize=10)

plt.title(f"2D PCA Visualization - '{word}' & Top-{TOP_K} Similar Words")
plt.xlabel("PC1")
plt.ylabel("PC2")
plt.legend()
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()

# ===== VẼ 3D: chỉ trung tâm + K láng giềng =====
fig = plt.figure(figsize=(8, 6))
ax = fig.add_subplot(111, projection='3d')

# trung tâm
ax.scatter(reduced_3d[center_idx, 0], reduced_3d[center_idx, 1],
           reduced_3d[center_idx, 2],
           s=150, color="red", label=f"center: {word}")
ax.text(reduced_3d[center_idx, 0], reduced_3d[center_idx, 1],
        reduced_3d[center_idx, 2],
        word, color="red", fontsize=10)

# láng giềng
for i in top_idx_3d:
    x, y, z = reduced_3d[i]
    ax.scatter(x, y, z, s=80, color="teal")
    ax.text(x, y, z, words_subset[i], fontsize=9)

ax.set_title(f"3D PCA Visualization - '{word}' & Top-{TOP_K} Similar Words")
ax.set_xlabel("PC1")
ax.set_ylabel("PC2")
ax.set_zlabel("PC3")
ax.legend()
plt.tight_layout()

```

```
plt.show()
```

Loaded vectors: vocab=1291147, dim=50


PCA done. 2D shape: (3000, 2), 3D shape: (3000, 3)

Top 10 nearest in REDUCED 2D space for 'king':


downtown	1.0000
center	1.0000
daniel	1.0000
located	1.0000
seat	1.0000
2015	1.0000
70	1.0000
born	1.0000
until	1.0000
came	1.0000

Top 10 nearest in REDUCED 3D space for 'king':

george	1.0000
fellow	0.9993
richard	0.9978
lord	0.9973
howard	0.9965
professor	0.9961
lee	0.9960
robert	0.9930
ben	0.9926
jean	0.9916



3D PCA Visualization — 'king' & Top-10 Similar Words



3 4. Nhận xét & Đánh giá cá nhân

3.1 Về phương pháp giảm chiều PCA

Phương pháp PCA (Principal Component Analysis) được sử dụng để giảm số chiều từ 50 về 2 và 3 giúp việc trực quan hóa dữ liệu dễ dàng hơn. PCA lựa chọn các trục tọa độ mới (các thành phần chính – principal components) sao cho giữ lại phần phương sai lớn nhất của dữ liệu ban đầu.

Tuy nhiên, PCA không bảo toàn được hoàn toàn mối quan hệ ngữ nghĩa giữa các từ, bởi vì nó chỉ tối ưu theo phương sai thống kê, không phải theo “nghĩa ngôn ngữ”. Do đó, sau khi giảm chiều, một số từ có thể trở nên gần nhau về mặt hình học nhưng không thật sự liên quan về nghĩa.

3.2 Kết quả quan sát được

3.2.1 Kết quả trong không gian 2D

Khi giảm chiều xuống 2D, kết quả cho thấy các từ tương đồng nhất với “king” là:

downtown, center, daniel, located, seat, 2015, 70, born, until, came

Các từ này không có ý nghĩa ngữ nghĩa gần “king”, mà chủ yếu là các danh từ hoặc từ phổ biến trong ngữ cảnh hoàn toàn khác. Điều này chứng tỏ rằng việc giảm chiều mạnh xuống 2D đã làm méo không gian vector, khiến các mối quan hệ ngữ nghĩa ban đầu bị phá vỡ gần như hoàn toàn. Nói cách khác, PCA-2D chỉ phản ánh hướng biến thiên lớn nhất về mặt toán học, chứ không còn mang nhiều giá trị ngôn ngữ học.

3.2.2 Kết quả trong không gian 3D

Sau khi giảm chiều xuống 3D, các từ gần nhất với “king” là:

george, fellow, richard, lord, howard, professor, lee, robert, ben, jean

Các từ này liên quan hơn nhiều đến bối cảnh “tên riêng” hoặc “danh hiệu”, phản ánh một phần ý nghĩa của từ “king” (liên quan đến người, danh xưng, quý tộc hoặc giới học giả). Điều này cho thấy PCA-3D giữ được cấu trúc ngữ nghĩa tốt hơn 2D, vì việc chỉ giảm còn 3 trục tọa độ vẫn đủ để bảo toàn một phần các mối tương quan chính giữa các vector từ.